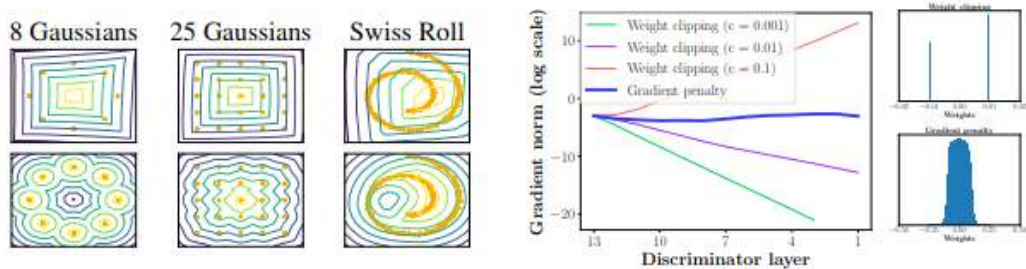


Improved Training of Wasserstein GANs

INTRODUCTION

- GAN은 학습의 불안정성이라는 단점이 존재
- WGAN의 경우 KL divergence등의 metric들의 발산성, 불연속성등의 문제를 해결하기 위해 새로운 loss function인 EM distance를 제안
부드럽게 수렴하며, 립시츠 조건만 만족하면 연속/미분가능성을 보장함을 증명하여, 이를 통해 mode collapsing과 발산 문제를 해결하지만, 더 좋은 방법을 고안
- WGAN에서는 립시츠 조건을 위하여 조금 non-formal한 방법인 clipping을 사용하고
Discriminator 학습 때마다 Weight을 인위적으로 clipping시켜 범위를 맞춤
- WGAN-GP에서는 gradient penalty방법을 사용하는데
이는 Discriminator Loss에 Gradient Norm을 패널티로 추가하는 방식

WEIGHT CLIPPING



Weight Clipping은 Network을 Simple한 Critic으로 유도할 수 있음 Capacity Underuse
Weight Clipping을 쓰면 Maximum Gradient Norm k 로 수렴하게 하여 simple function을 유도

좌측 상단의 그래프가 Clipping을 사용한 그래프, 아래가 Penalty를 사용한 그래프
상단의 그래프가 간단한 구조 \rightarrow 점들의 분포를 반영하기 어렵고, 어려운 분포일수록 문제가 심해짐

우측 그래프를 통해 Weight Clipping을 사용한 경우, Gradient Norm이 1로 수렴하지 않고 발산하는 것을 확인할 수 있음

이러한 방식으로 학습될 경우 우측 상단의 그림처럼 Weight의 분포가 불균일해질 수 있음
하지만 Penalty 방식은 우측 하단의 그래프와 같이 학습

즉, Weight Clipping은 Gradient Norm을 1이 아닌 Maximum Gradient Norm으로 수렴하도록 하여, 보다 간단한 함수를 학습하게 하며 weight 분포를 불균일하게 만든다. 이러한 현상들이 Gradient Vanishing등의 문제를 일으킨 것이다.

Gradient Penalty

1-립시츠 조건을 만족시켜주기 위하여 Gradient Norm을 1로 맞춰주는 것을 목표로 함
Penalty에서 사용하는 \hat{x} 의 분포는 P_g , P_r 사이의 interpolation에서 random하게 sampling 되어 사용


$$L = \underbrace{\mathbb{E}_{\hat{x} \sim P_g} [D(\hat{x})] - \mathbb{E}_{x \sim P_r} [D(x)]}_{\text{Original critic loss}} + \underbrace{\lambda \mathbb{E}_{\hat{x} \sim P_{\hat{x}}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]}_{\text{Our gradient penalty}}.$$

-> Penalty를 통해 P_g 와 P_r 사이 interpolation 분포의 Critic Gradient Norm을 1에 근접하도록 학습시킴

Experiments



Figure 2: Different GAN architectures trained with different methods. We only succeeded in training every architecture with a shared set of hyperparameters using WGAN-GP.



보통의 GAN의 목적 함수에 우리의 Penalty Term을 적용하여 Discriminator가 더 부드러운 결정 경계를 학습하도록 격려되어 학습을 안정화